Guía de observación
EDA 03: cobertura Landsat y rendimiento 2025

Proyecto AgroCebada

Índice

1. Propósito y definición de cobertura **2**

2. Cobertura por parcela **2**
- 2.1. Cobertura Landsat utilizable ordenada . . . 2
- 2.2. Distribución de cobertura total y utilizable . . . 3
- 2.3. Cobertura histórica frente al ciclo 2025 . . . 3
- 2.4. Cobertura mensual de Landsat . . . 4
- 2.5. Huecos temporales por grupo . . . 5

3. Relación con atributos de parcela y objetivo **6**
- 3.1. Cobertura utilizable frente al área . . . 6
- 3.2. Cobertura utilizable frente al rendimiento . . . 7
- 3.3. Distribución espacial de los grupos . . . 8

4. Respuestas y hallazgos **8**
- 4.1. Grupos y disponibilidad . . . 8
- 4.2. Área, rendimiento y espacio . . . 9

5. ¿Debe darse peso a las parcelas según su cobertura? **9**

6. Qué representa el rendimiento **10**

7. Conclusión operativa **10**

1. Propósito y definición de cobertura

Este EDA estudia por qué Landsat tiene cobertura desigual entre parcelas y cómo representar esa desigualdad antes del modelado. La cobertura histórica se calcula respecto a las 392 fechas Landsat presentes entre 2022 y 2025. También se calcula la cobertura específica del ciclo objetivo, abril–octubre de 2025, que contiene 53 fechas disponibles.

El criterio principal de agrupación es la proporción de fechas históricas con `vi6t_promedio` válido. Los grupos se forman con los cuartiles de esta proporción: baja hasta 0.3597, media entre 0.3597 y 0.4158, y alta por encima de 0.4158. Es una segmentación descriptiva y reproducible, no un resultado de un modelo de clustering.

2. Cobertura por parcela

2.1. Cobertura Landsat utilizable ordenada

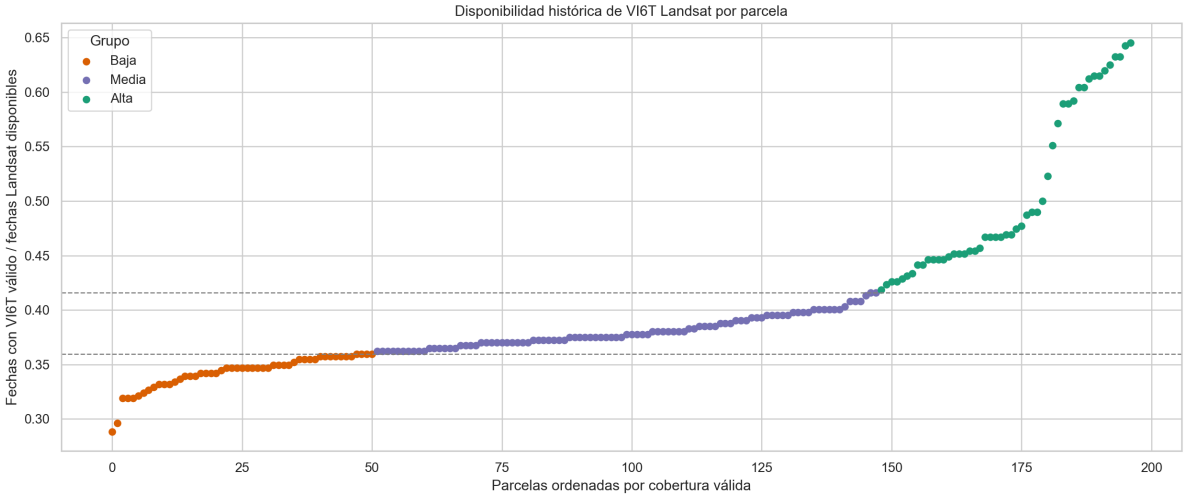


Figura 1: Cobertura Landsat utilizable ordenada

Preguntas guía

- ¿La cobertura cambia gradualmente o existen grupos separados?
- ¿Cuántas parcelas pertenecen a cada nivel?
- ¿Los umbrales representan calidad agronómica o sólo disponibilidad relativa?

2.2. Distribución de cobertura total y utilizable

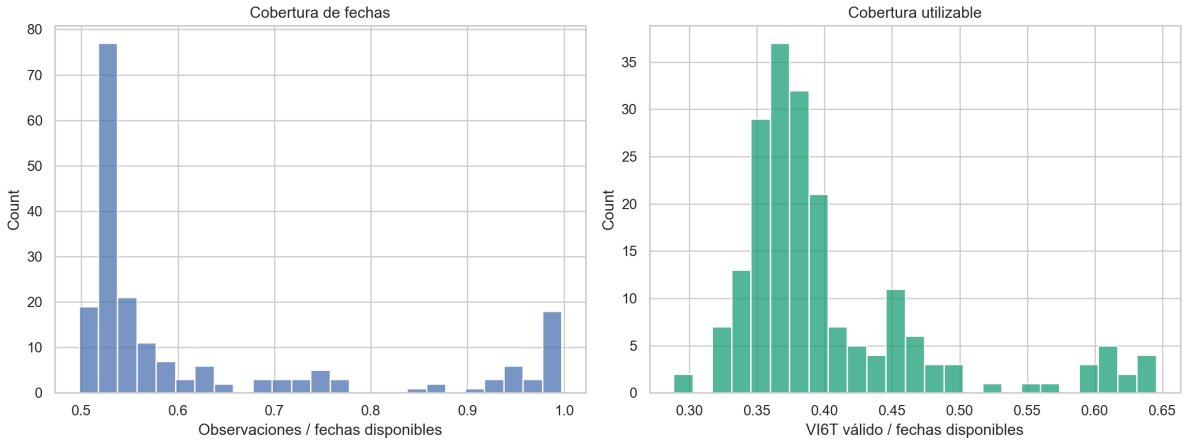


Figura 2: Distribución de cobertura total y utilizable

Preguntas guía

- ¿Cuánto disminuye la cobertura al exigir un VI6T válido?
- ¿Hay parcelas con muchas capturas pero pocos valores utilizables?
- ¿Conviene usar número de filas o número de valores válidos como indicador de confianza?

2.3. Cobertura histórica frente al ciclo 2025

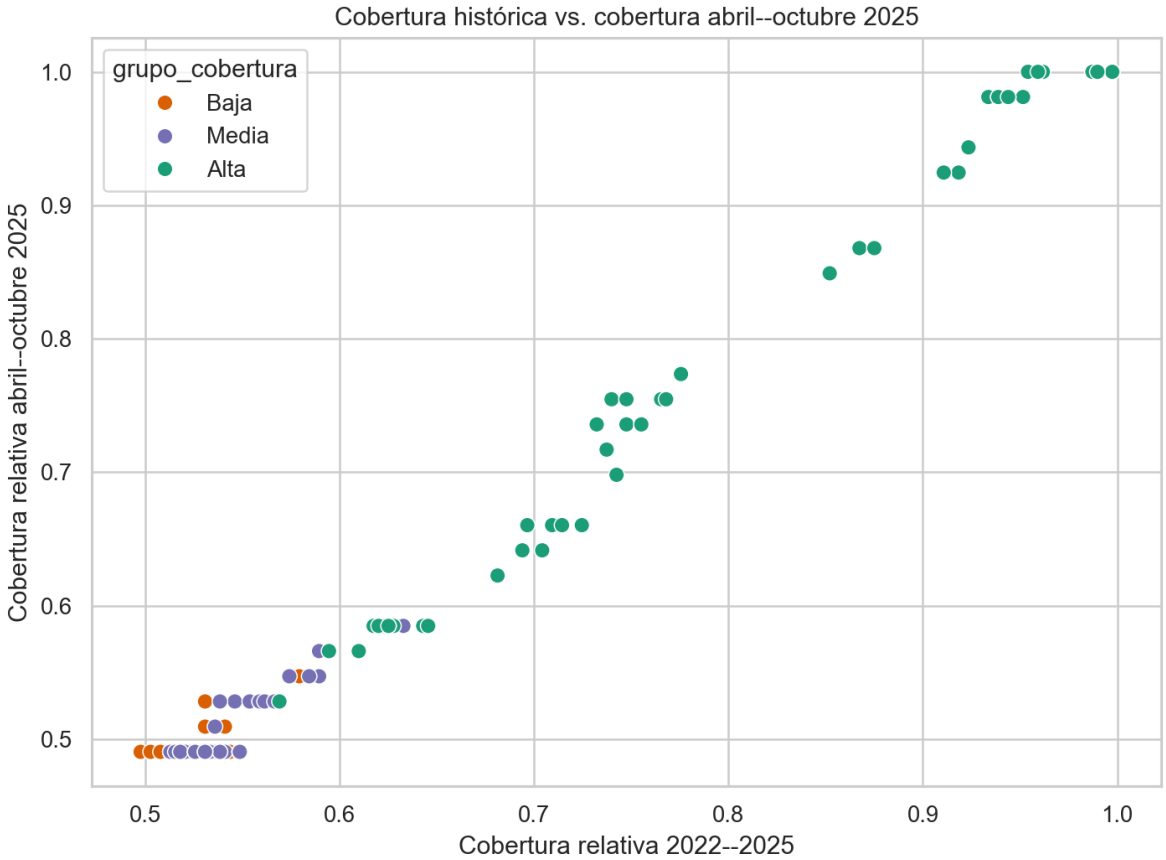


Figura 3: Cobertura histórica frente al ciclo 2025

Preguntas guía

- ¿La cobertura histórica predice la disponibilidad durante abril–octubre de 2025?
- ¿Existen parcelas con buena historia pero mala cobertura en el ciclo objetivo?
- ¿Qué cobertura debe tener prioridad para predecir el rendimiento 2025?

2.4. Cobertura mensual de Landsat

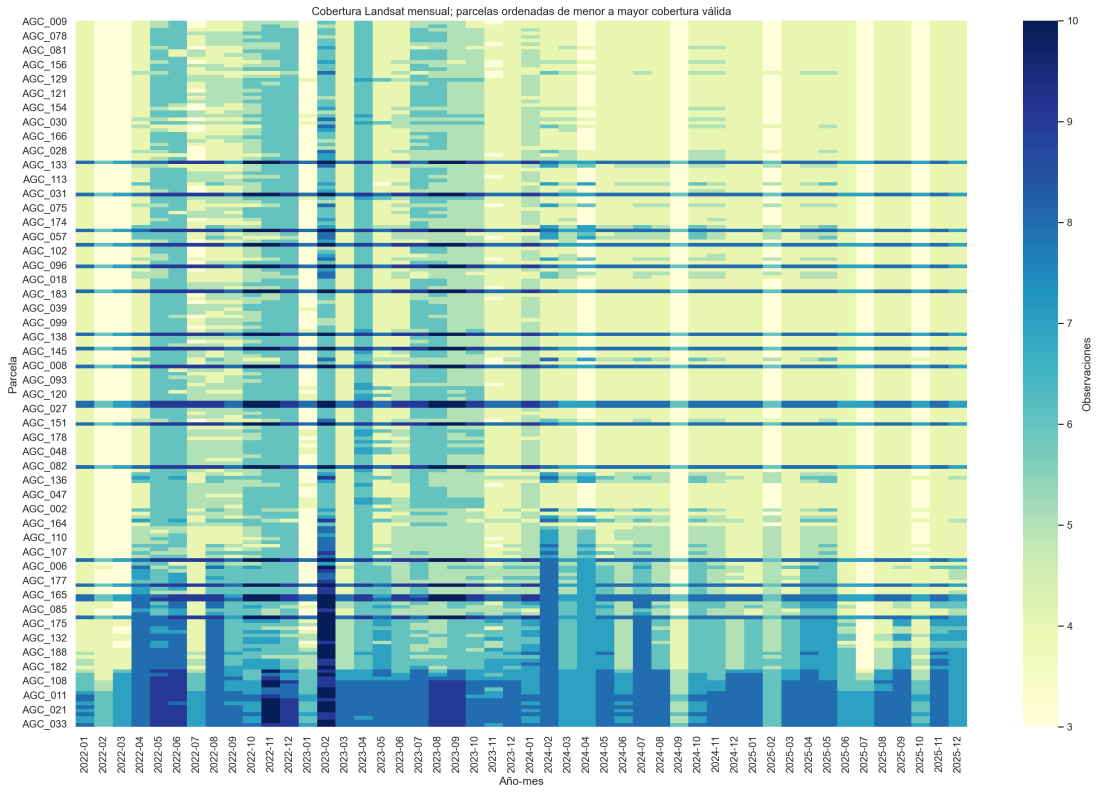


Figura 4: Cobertura mensual de Landsat

Preguntas guía

- ¿La baja cobertura se concentra en meses o parcelas específicas?
- ¿Hay bloques persistentes que indiquen grupos de adquisición distintos?
- ¿Las parcelas con menos datos conservan observaciones dentro del ciclo 2025?

2.5. Huecos temporales por grupo

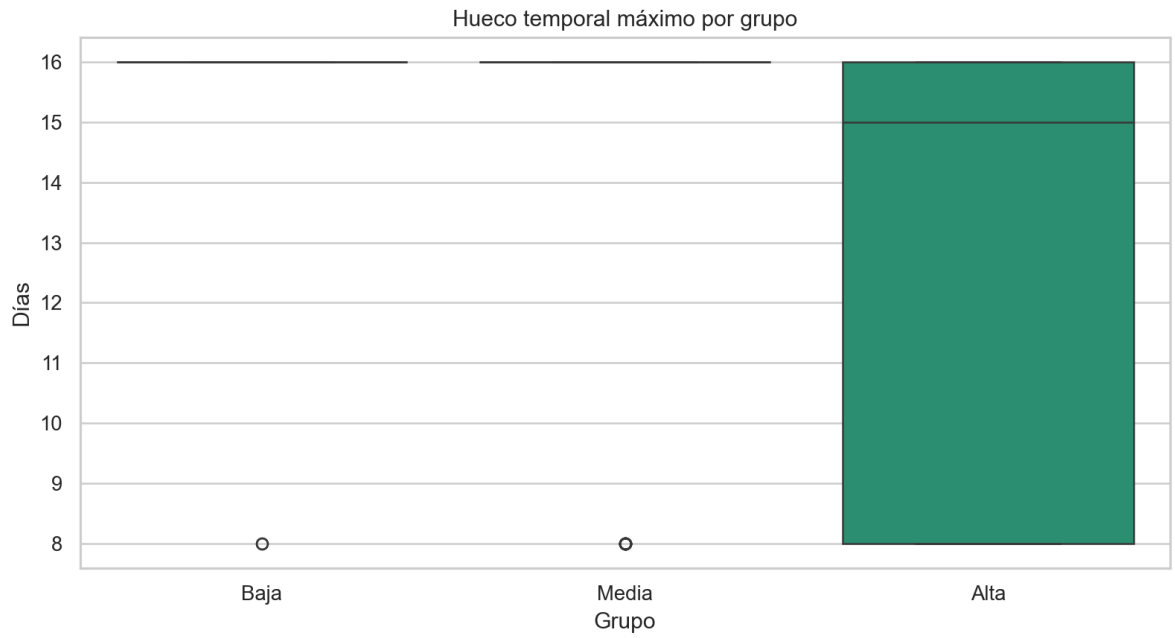


Figura 5: Huecos temporales por grupo

Preguntas guía

- ¿Los grupos con menor cobertura también tienen huecos máximos mayores?
- ¿La diferencia principal es continuidad o cantidad total de observaciones?
- ¿Los huecos son suficientemente grandes para impedir agregaciones mensuales?

3. Relación con atributos de parcela y objetivo

3.1. Cobertura utilizable frente al área

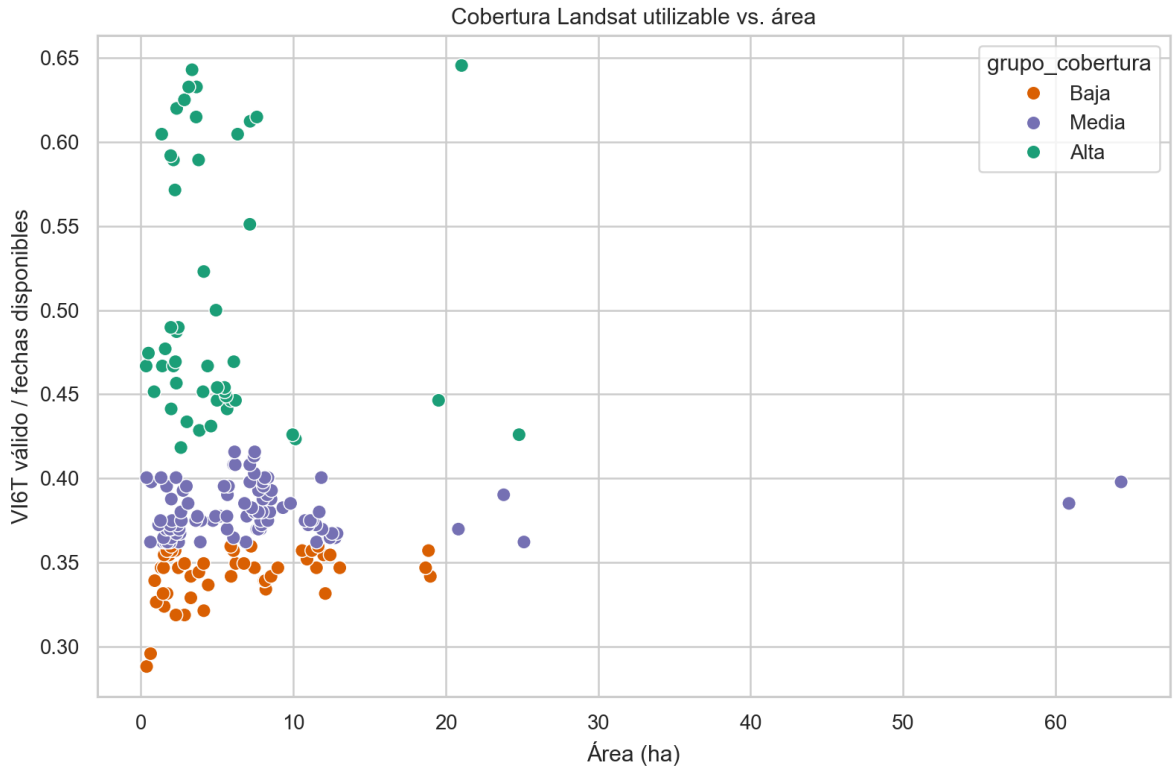


Figura 6: Cobertura utilizable frente al área

Preguntas guía

- ¿Las parcelas pequeñas reciben sistemáticamente menor cobertura?
- ¿El área explica los grupos observados?
- ¿Debe el área formar parte del control de calidad o del modelo agronómico?

3.2. Cobertura utilizable frente al rendimiento

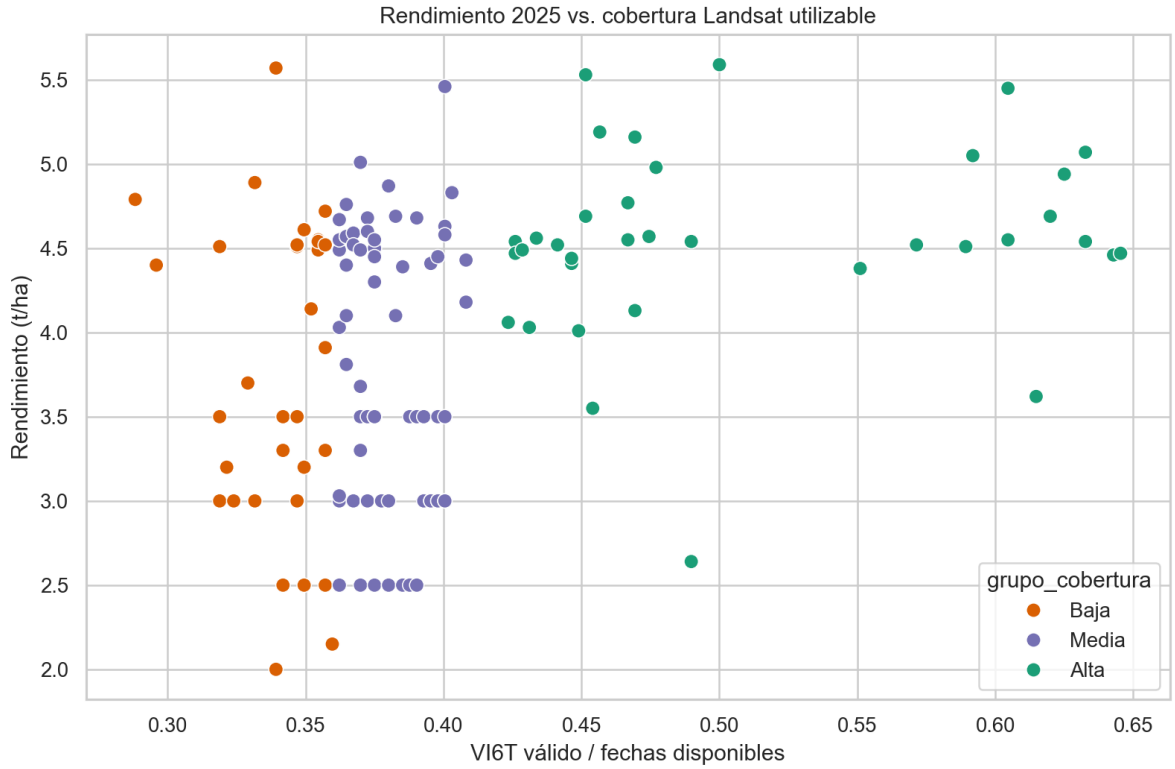


Figura 7: Cobertura utilizable frente al rendimiento

Preguntas guía

- ¿Existe asociación entre cobertura y rendimiento en entrenamiento?
- ¿La asociación puede deberse a geografía, manejo, fenología o calidad de medición?
- ¿Sería seguro usar la cobertura como peso de entrenamiento?

3.3. Distribución espacial de los grupos



Figura 8: Distribución espacial de los grupos

Preguntas guía

- ¿Los grupos de cobertura forman conglomerados espaciales?
- ¿La cobertura podría estar actuando como sustituto de municipio, órbita o región?
- ¿Cómo debe diseñarse la validación para evitar aprovechar accidentalmente esa estructura espacial?

4. Respuestas y hallazgos

4.1. Grupos y disponibilidad

1. La distribución no es completamente continua: aparece un grupo superior con cobertura claramente mayor. Hay 51 parcelas en cobertura baja, 97 en media y 49 en alta. Los límites son cuartiles del conjunto actual y no umbrales de calidad agronómica universal.

2. La mediana de observaciones históricas es 205, 208 y 296 para los grupos bajo, medio y alto. Sin embargo, las medianas de VI6T válido son solamente 136, 148 y 184. Por ello, contar filas sobreestima la información utilizable. La proporción de VI6T válido respecto a las 392 fechas disponibles es el indicador de confianza más directo de los evaluados.

3. En abril–octubre de 2025, la cobertura mediana relativa es 0.491 en los grupos bajo y medio y 0.755 en el alto. La historia ayuda a anticipar la disponibilidad del ciclo objetivo, pero no la sustituye. Para predecir el rendimiento 2025 debe priorizarse la cobertura dentro de abril–octubre; la cobertura 2022–2024 debe considerarse contexto histórico.

4. El heatmap indica que la diferencia es persistente por parcela y no la ausencia de un único mes global. Incluso los grupos bajos conservan datos en el ciclo objetivo, de modo que pueden producir agregados mensuales, aunque con menor estabilidad y diferente número de observaciones.

5. Los huecos máximos medianos son muy parecidos: 16 días en los grupos bajo y medio y 15 en el alto. La separación entre grupos se debe principalmente al número total de capturas y valores VI6T válidos, no a interrupciones extremas mucho mayores. Huecos de este tamaño permiten agregación mensual, pero deben registrarse el número de observaciones y los días cubiertos.

4.2. Área, rendimiento y espacio

6. El área casi no explica la cobertura utilizable: la correlación de Spearman es −0,027. Las medianas de área son 4.13 ha en cobertura baja, 6.89 ha en media y 3.79 ha en alta, sin un gradiente consistente. El área puede ser una variable agronómica, pero no debe utilizarse como sustituto de calidad.

7. Sí existe una asociación descriptiva entre cobertura y rendimiento. La correlación Spearman es 0.290 para cobertura VI6T válida y 0.378 para número de observaciones. El rendimiento medio por grupo es 3.72, 3.76 y 4.55 t/ha; las medianas son 3.50, 3.50 y 4.54. Esto no significa que observar más eleve el rendimiento: la cobertura puede estar capturando región, órbita, condiciones del cultivo o diferencias del proceso de datos.

8. Los grupos contienen parcelas de ambos conjuntos: baja tiene 33 de entrenamiento y 18 de predicción; media, 69 y 28; alta, 36 y 13. No hay un grupo exclusivo del conjunto oculto. El mapa debe usarse para determinar si el grupo alto se concentra espacialmente; si es así, una partición aleatoria puede producir resultados demasiado optimistas y conviene validar por grupos espaciales o municipios.

5. ¿Debe darse peso a las parcelas según su cobertura?

Es razonable probarlo, pero no asumir que es correcto. El archivo de métricas incluye un peso candidato de cobertura, definido como la proporción histórica de VI6T válido dividida entre la mayor proporción observada. Este peso expresa disponibilidad, no certeza del rendimiento ni importancia agronómica.

Se recomiendan tres experimentos bajo las mismas particiones de validación:

1. modelo sin peso, incorporando cobertura y número de observaciones como variables;

2. modelo con peso candidato durante el entrenamiento;

3. agregados temporales acompañados por su conteo, dispersión y cobertura, sin ponderar la pérdida.

Debe elegirse la opción por desempeño fuera de muestra en cada grupo de cobertura, no sólo por el error global. Ponderar hacia abajo las parcelas de baja cobertura podría perjudicar precisamente a las 18 parcelas de predicción de ese grupo.

6. Qué representa el rendimiento

La documentación oficial indica que `RENDIMIENTO_T_HA` es el rendimiento de cebada en toneladas por hectárea correspondiente al ciclo productivo abril–octubre de 2025. La tabla contiene una fila por parcela, no una serie temporal: 138 parcelas de `ENTRENAMIENTO` tienen rendimiento y las 59 de `PREDICCION` lo mantienen oculto.

No se proporciona una fecha exacta de cosecha por parcela. "Abril–octubre de 2025" es una ventana de ciclo, no evidencia de que todas las parcelas hayan sido cosechadas el mismo día. Tampoco hay rendimientos etiquetados para 2022, 2023 o 2024. Esos años pueden aportar climatología o comportamiento histórico, pero no constituyen ejemplos adicionales de entrenamiento supervisado.

Para evitar fuga de información, la construcción de variables debe fijar un momento de predicción. Si el objetivo es estimar al final del ciclo, pueden usarse capturas hasta octubre de 2025. Si se desea predicción anticipada, deben definirse cortes reproducibles, por ejemplo hasta junio, julio, agosto o septiembre, y eliminar toda observación posterior a cada corte.

7. Conclusión operativa

Sentinel-2 puede ser la columna vertebral por uniformidad y riqueza de variables. Landsat sigue siendo útil como señal complementaria: su cobertura no invalida el sensor, pero exige conservar métricas de disponibilidad, agregar dentro de ventanas comunes y evaluar desempeño por grupo. El peso por cobertura debe ser un experimento de validación, no una corrección automática.