Guía de observación
EDA 04: parcelas y rendimiento observado

Proyecto AgroCebada

Índice

1. Fuentes y propósito **2**

2. Exploración visual **2**

2.1. Rendimiento observado por parcela 2
2.2. Disponibilidad espacial del rendimiento 3
2.3. Distribución global del rendimiento 3
2.4. Rendimiento por estado 4
2.5. Rendimiento medio por municipio 5
2.6. Área frente a rendimiento 6

3. Respuestas y hallazgos **6**

3.1. Mapa de rendimiento 6
3.2. Distribución del objetivo 6
3.3. Estado y municipio 7
3.4. Área y rendimiento 7

4. Implicaciones para el modelo **7**

1. Fuentes y propósito

La ubicación y forma de las parcelas provienen de `data/original/02_conjunto_70_30/Parcelas_Reto_AGC_C`. El shapefile usa el sistema EPSG:4326 y guarda el identificador como `ID_POLIGON`, nombre truncado por la limitación del formato. El script lo renombra a `ID_POLIGONO` y lo une uno a uno con `ID_area_rendimiento_70_30_Reto_AgroCebada.csv`.

El rendimiento corresponde al ciclo abril–octubre de 2025. Está observado para 138 parcelas de entrenamiento y oculto para 59 parcelas de predicción. El gris en los mapas significa rendimiento oculto, no rendimiento cero.

2. Exploración visual

2.1. Rendimiento observado por parcela

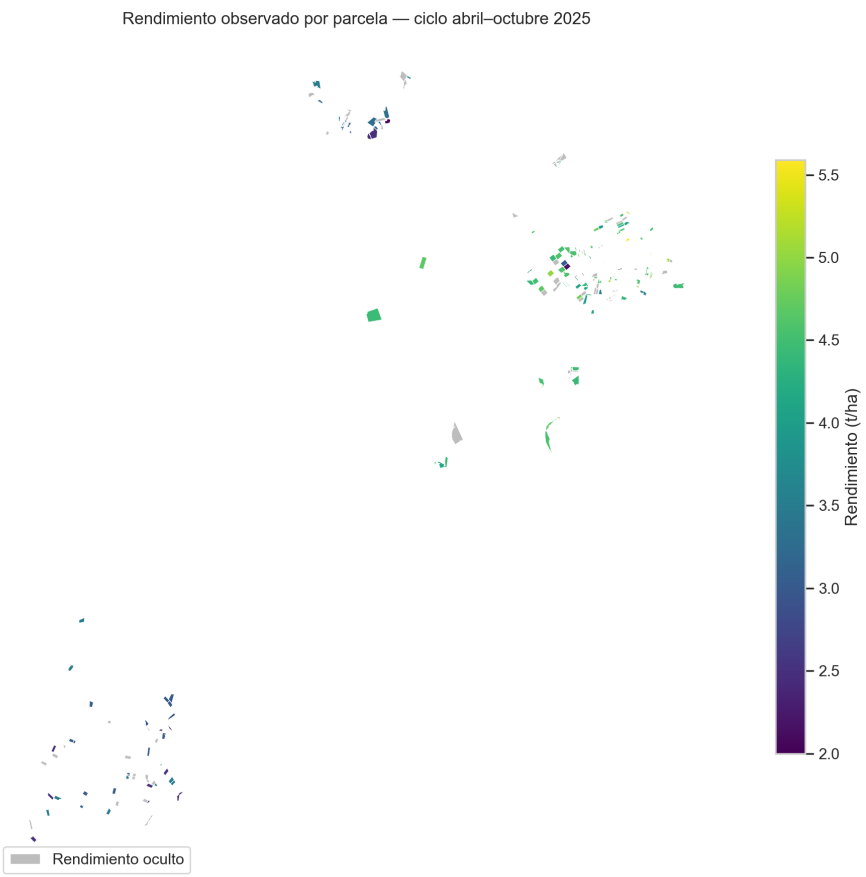


Figura 1: Rendimiento observado por parcela

Preguntas guía

- ¿Los rendimientos altos y bajos forman patrones espaciales?
- ¿Las parcelas grises están distribuidas entre las mismas regiones que las observadas?
- ¿Puede la ubicación explicar parte de la variación del rendimiento?

2.2. Disponibilidad espacial del rendimiento



Figura 2: Disponibilidad espacial del rendimiento

Preguntas guía

- ¿El conjunto de predicción ocupa regiones sin representación en entrenamiento?
- ¿Existe concentración espacial de etiquetas faltantes?
- ¿La proporción 70/30 se conserva aproximadamente por estado?

2.3. Distribución global del rendimiento

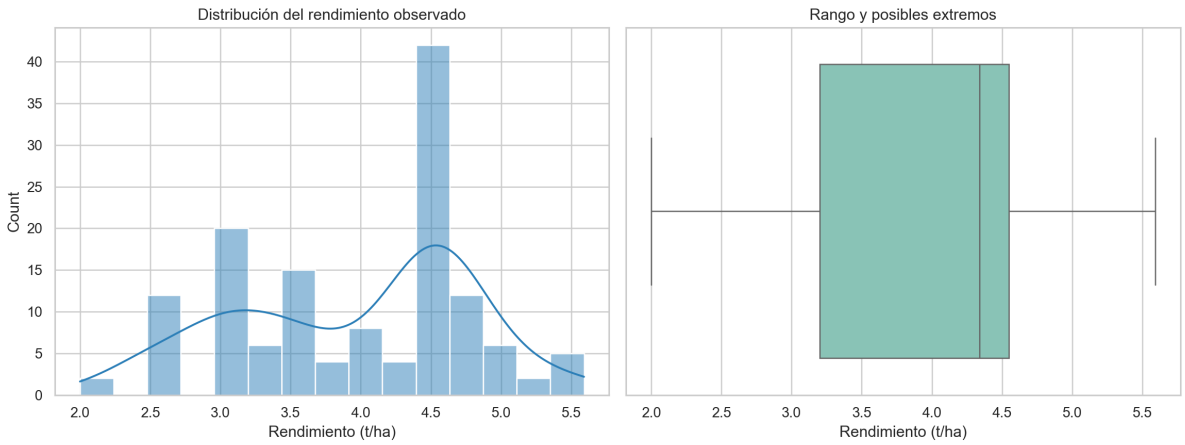


Figura 3: Distribución global del rendimiento

Preguntas guía

- ¿Cuál es el centro y rango de los rendimientos observados?
- ¿La distribución es simétrica, multimodal o presenta valores extremos?
- ¿Hay evidencia para transformar la variable objetivo?

2.4. Rendimiento por estado

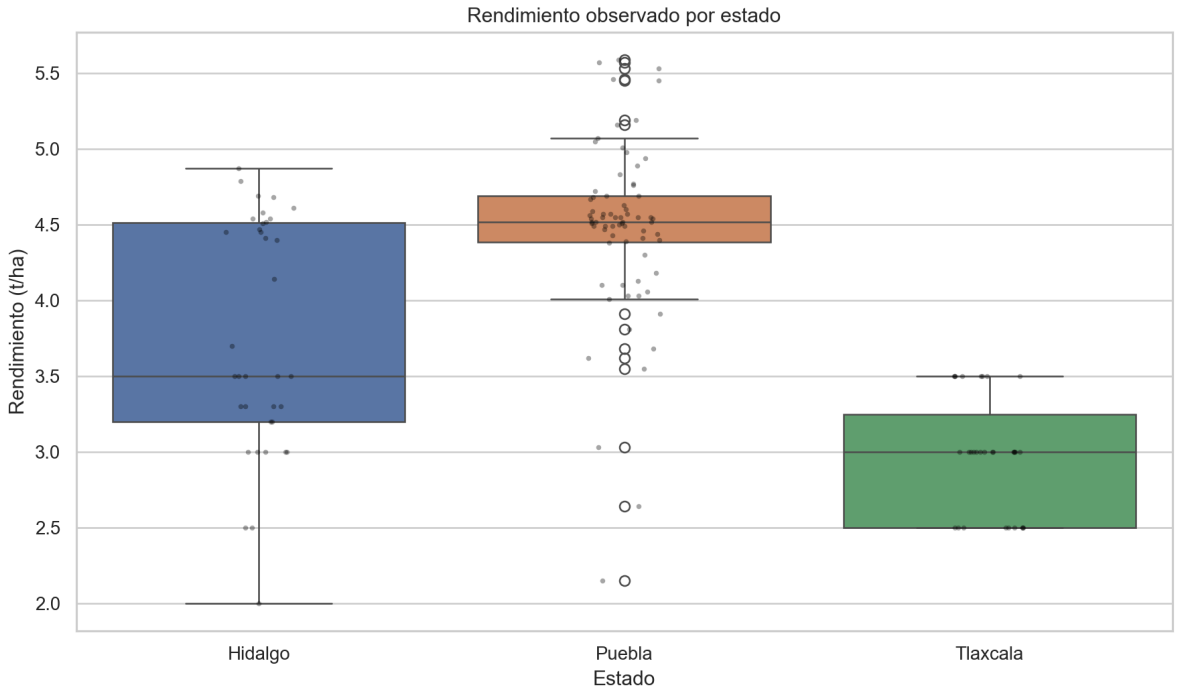


Figura 4: Rendimiento por estado

Preguntas guía

- ¿Las diferencias entre estados son mayores que la variación interna?
- ¿Qué estado tiene mayor rendimiento y cuál menor?
- ¿Cómo afecta esto a la estrategia de validación?

2.5. Rendimiento medio por municipio

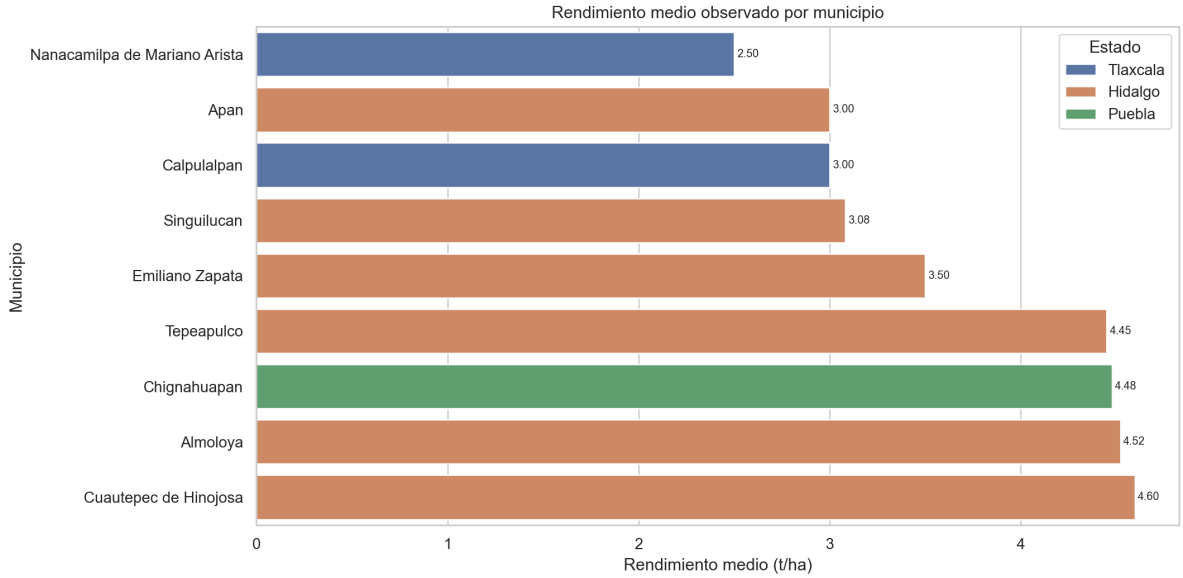


Figura 5: Rendimiento medio por municipio

Preguntas guía

- ¿Qué municipios concentran rendimientos altos y bajos?
- ¿Cuáles promedios se apoyan en muy pocas parcelas?
- ¿Municipio debe emplearse como predictor, grupo de validación o ambos?

2.6. Área frente a rendimiento

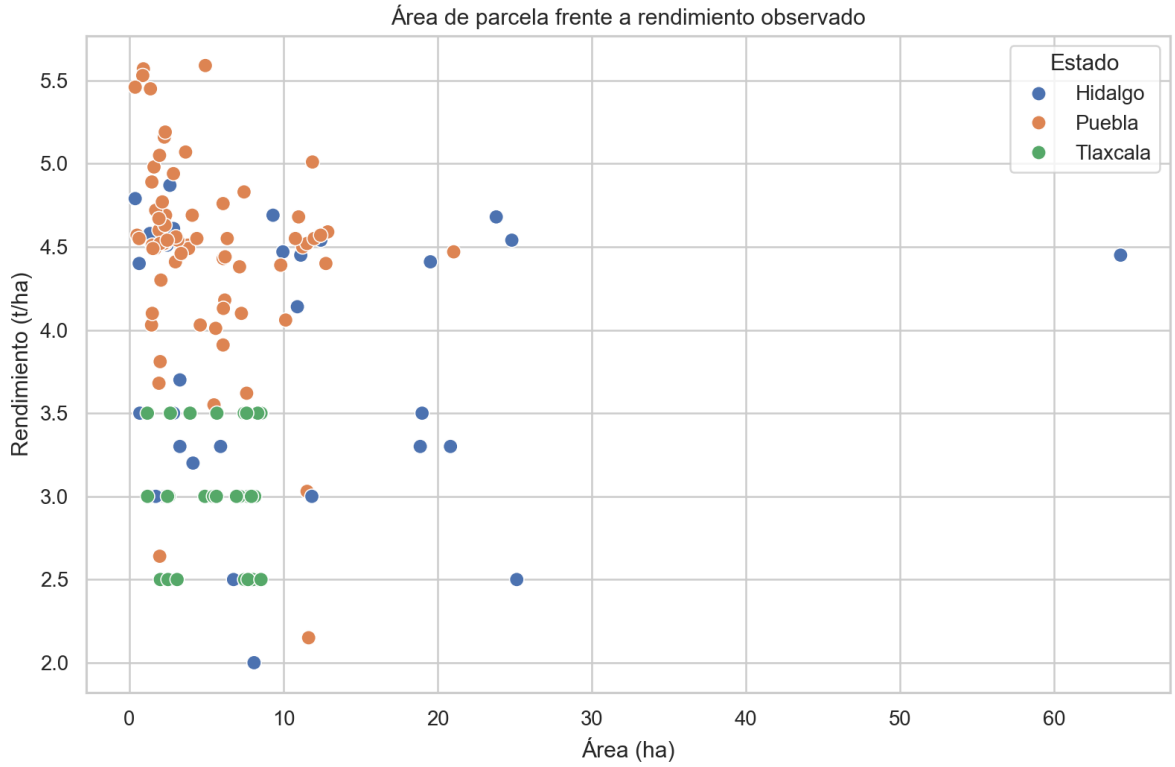


Figura 6: Área frente a rendimiento

Preguntas guía

- ¿Las parcelas grandes tienen sistemáticamente mayor rendimiento por hectárea?
- ¿La aparente relación cambia por estado?
- ¿El área puede estar confundida con la ubicación?

3. Respuestas y hallazgos

3.1. Mapa de rendimiento

Los valores altos se concentran principalmente en Puebla y en algunos municipios de Hidalgo, mientras que Tlaxcala presenta valores bajos y compactos. Esto muestra una estructura espacial clara: ubicación, clima, altitud, suelo o manejo pueden explicar una fracción importante del objetivo. Las parcelas grises aparecen en los tres estados y dentro de regiones que también contienen entrenamiento; no forman una región completamente nueva.

La separación observada/oculta conserva aproximadamente el diseño 70/30 dentro de cada estado: Hidalgo tiene 36 observadas y 15 ocultas; Puebla, 71 y 29; Tlaxcala, 31 y 15. Por tanto, existe representación geográfica general, aunque esto no garantiza cobertura suficiente para cada municipio pequeño.

3.2. Distribución del objetivo

Entre las 138 parcelas observadas, el rendimiento medio es 3.96 t/ha y la mediana 4.34 t/ha. El rango es 2.00–5.59, con cuartiles 3.20 y 4.55 y desviación estándar 0.85. La media menor que la mediana refleja una cola hacia rendimientos bajos y la combinación de poblaciones regionales. No hay evidencia suficiente para exigir una transformación logarítmica; primero debe evaluarse el objetivo en su escala original, que además facilita interpretar MAE y RMSE en t/ha.

3.3. Estado y municipio

Puebla tiene el rendimiento medio más alto, 4.48 t/ha, seguido de Hidalgo con 3.76 y Tlaxcala con 2.98. Las medianas son 4.52, 3.50 y 3.00. Las diferencias entre estados son grandes respecto a la dispersión interna, especialmente en Tlaxcala, cuya desviación es 0.38.

Por municipio destacan Cuautepec de Hinojosa (4.60), Almoloya (4.52) y Chignahuapan (4.48). En el extremo bajo aparecen Nanacamilpa (2.50), Calpulalpan (3.00) y Singuilucan (3.08). Sin embargo, Apan, Tepeapulco y Nanacamilpa tienen sólo una etiqueta observada; sus medias no son estimaciones estables. Municipio puede ser útil como variable y como grupo diagnóstico, pero una codificación directa puede sobreajustar categorías pequeñas.

3.4. Área y rendimiento

No se observa que las parcelas grandes tengan sistemáticamente mayor rendimiento por hectárea. La correlación de Spearman es aproximadamente $-0{,}25$, débil a moderada y negativa. Parte de esa asociación puede deberse a que el tamaño de las parcelas también cambia entre estados. El área debe conservarse como predictor, pero su efecto debe evaluarse controlando ubicación y sin interpretarlo como causal.

4. Implicaciones para el modelo

1. Incluir estado, municipio, coordenadas del centroide, elevación y pendiente como candidatos, evitando depender únicamente de categorías administrativas.

2. Comparar validación aleatoria con validación agrupada por municipio o por bloques espaciales. Una partición aleatoria puede sobreestimar la capacidad de generalizar a otra zona.

3. Reportar MAE por estado, municipio y grupo de cobertura Landsat, además del error global.

4. No imputar el rendimiento de las 59 parcelas durante entrenamiento. Son el conjunto final de inferencia, no valores faltantes comunes.

5. Mantener t/ha como escala inicial y usar abril–octubre de 2025 como ciclo objetivo, cuidando que las variables respeten la fecha de corte de predicción.